Линейная регрессия



Елена Кантонистова
ekantonistova@hse.ru

План лекции

1. Линейная регрессия: напоминание и пример
2. Функция потерь: MSE, MAE, квантильная
3. Нечисловые и «нелинейные» признаки
4. Аналитическое решение задачи МНК

1

Линейная регрессия

Напоминание: модель, обозначения и небольшой пример целиком

Линейная регрессия

Пример (напоминание)

Хотим предсказать стоимость дома y по его площади x_1 и количеству комнат x_2.

$$a(x) = w_0 + w_1 x_1 + w_2 x_2$$



где w_0, w_1, w_2 — параметры модели (веса).

Линейная регрессия

Пример (напоминание)

Хотим предсказать стоимость дома y по его площади x_1 и количеству комнат x_2.

$$a(x) = w_0 + w_1 x_1 + w_2 x_2$$



где w_0, w_1, w_2 — параметры модели (веса).

Что нам даёт такая модель

- прогноз для нового объекта — подставили признаки, получили число;
- интерпретацию — вес показывает, на сколько меняется прогноз при росте признака на единицу.

Линейная регрессия: общий вид

$$a(x) = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

где $x_1, \ldots, x_n$ — признаки объекта x, а n — их количество.

Сокращённая запись:

$$a(x) = w_0 + \sum_{j=1}^{n} w_j x_j$$

Сумма по всем признакам, отдельно стоит свободный член w_0 (его ещё называют сдвигом, intercept).

Линейная регрессия: векторная запись

Добавим фиктивный признак $x_0 = 1$ — тогда свободный член перестанет выбиваться из общей суммы:

$$a(x) = w_0 \cdot 1 + \sum_{j=1}^{n} w_j x_j = \sum_{j=0}^{n} w_j x_j = \langle w, x \rangle$$

$$a(x) = \langle w, x \rangle$$

Вся модель — одно скалярное произведение вектора весов на вектор признаков. Дальше всюду пользуемся этой записью.

Что значит «обучить модель»

Обучение линейной регрессии — минимизация среднеквадратичной ошибки по весам:

$$Q(a, X) = \frac{1}{l}\sum_{i=1}^{l}\big(a(x_i) - y_i\big)^2 = \frac{1}{l}\sum_{i=1}^{l}\big(\langle w, x_i\rangle - y_i\big)^2 \to \min_w$$

здесь l — количество объектов обучающей выборки

Что фиксировано

Данные: объекты $x_1, \ldots, x_l$ и их ответы $y_1, \ldots, y_l$. Мы их не меняем.

Что подбираем

Веса $w_0, w_1, \ldots, w_n$ — ровно n + 1 число. Это и есть «обучение».

Разберём пример целиком

Шаг 1. Данные: шесть домов



№	Площадь x_1, м²	Комнат x_2	Цена y, млн ₽
1	35	1	6.0
2	45	2	8.2
3	55	2	9.5
4	62	3	11.0
5	78	3	13.4
6	95	4	16.1

Обозначения

- $l = 6$ — объектов
- $n = 2$ — признака
- X — матрица 6 × 3 (с колонкой единиц)
- y — вектор из 6 чисел

Данные учебные: настоящая выборка по недвижимости — это тысячи объектов и десятки признаков.

Разберём пример целиком

Шаг 2. Обучили модель — получили веса

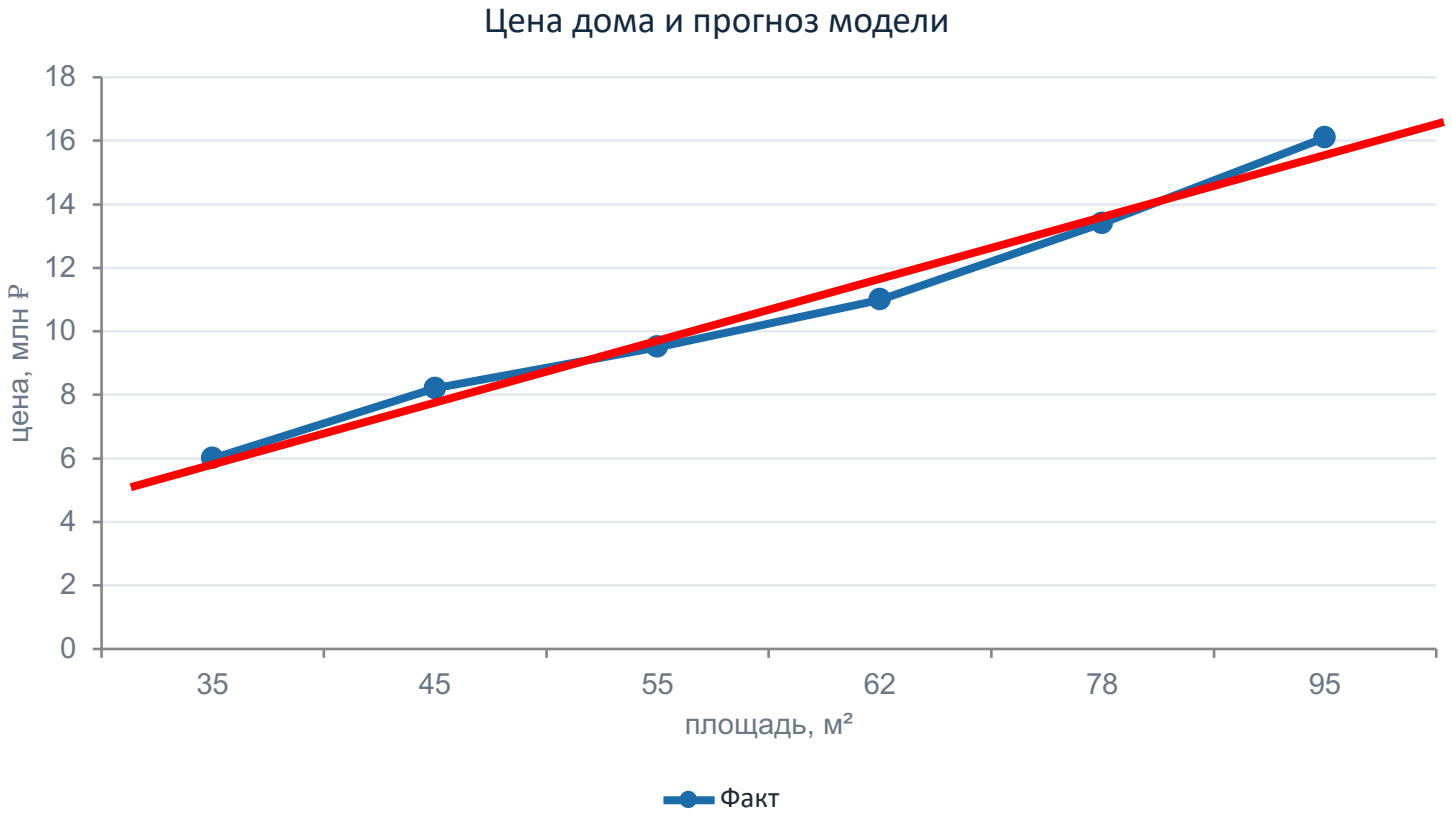
$$a(x) = 0.68 + 0.138\,x_1 + 0.600\,x_2$$

Как это читать

$w_1 = 0.138$	каждый дополнительный квадратный метр добавляет к прогнозу примерно 138 тыс. ₽ — при том же числе комнат
$w_2 = 0.600$	лишняя комната при той же площади добавляет ≈ 600 тыс. ₽
$w_0 = 0.68$	формальный сдвиг (базовый уровень цены)

Разберём пример целиком

Шаг 3. Смотрим, как модель ложится на данные



Что видно

Прогноз идёт почти вплотную к факту, но нигде не совпадает с ним точно. Это нормально: модель — не таблица, она сглаживает данные.

Разберём пример целиком

Шаг 4. Прогноз для нового дома и остатки на обучающих данных

Новый дом: 70 м², 3 комнаты

$$a = 0.68 + 0.138 \cdot 70 + 0.600 \cdot 3 \approx 12.15$$

млн ₽

Дом	Факт y	Прогноз a(x)	Остаток y − a(x)
1	6.0	6.12	−0.12
2	8.2	8.10	+0.10
3	9.5	9.48	+0.02
4	11.0	11.05	−0.05
5	13.4	13.26	+0.14
6	16.1	16.21	−0.11

Разберём пример целиком

Шаг 4. Прогноз для нового дома и остатки на обучающих данных

Новый дом: 70 м², 3 комнаты

$$a = 0.68 + 0.138 \cdot 70 + 0.600 \cdot 3 \approx 12.15$$

млн ₽

Важный вопрос

Откуда берутся веса?

Дом	Факт y	Прогноз a(x)	Остаток y − a(x)
1	6.0	6.12	−0.12
2	8.2	8.10	+0.10
3	9.5	9.48	+0.02
4	11.0	11.05	−0.05
5	13.4	13.26	+0.14
6	16.1	16.21	−0.11

Разберём пример целиком

Шаг 4. Прогноз для нового дома и остатки на обучающих данных

Новый дом: 70 м², 3 комнаты

$$a = 0.68 + 0.138 \cdot 70 + 0.600 \cdot 3 \approx 12.15$$

млн ₽

Важный вопрос

Веса взялись не из воздуха: **их подобрали так, чтобы остатки были как можно меньше**.
Но что значит «меньше» для целого столбца чисел?

Дом	Факт y	Прогноз a(x)	Остаток y − a(x)
1	6.0	6.12	−0.12
2	8.2	8.10	+0.10
3	9.5	9.48	+0.02
4	11.0	11.05	−0.05
5	13.4	13.26	+0.14
6	16.1	16.21	−0.11

2

Функция потерь

Как одним числом измерить, насколько модель плоха

Первая идея

Просто сложим остатки:

$$Q = \sum_{i=1}^{l} \big(a(x_i) - y_i\big)$$

Первая идея

Просто сложим остатки:

$$Q = \sum_{i=1}^{l} \big(a(x_i) - y_i\big)$$

Почему так нельзя

Пусть на одном доме модель ошиблась на +5 млн, а на другом на −5 млн. Сумма остатков равна нулю — формально «идеальная» модель, хотя обе оценки катастрофически плохие.

Ошибки разных знаков гасят друг друга. Значит, знак нужно убрать.

Как убрать знак?

Два естественных способа

Модуль

$$\left|a(x_i) - y_i\right|$$

Честно измеряет расстояние.

Квадрат

$$\left(a(x_i) - y_i\right)^2$$

Тоже убирает знак, гладкий всюду, легко дифференцируется. Именно его берут по умолчанию.

Оба варианта рабочие. Дальше разберём каждый и увидим, что выбор зависит от того, как устроены ваши данные.

MSE — среднеквадратичная ошибка

Mean Squared Error

$$\mathrm{MSE}(a, X) = \frac{1}{l}\sum_{i=1}^{l}\big(a(x_i) - y_i\big)^2$$

Почему именно квадрат — три причины

1. **Убирает знак.** ошибки +5 и −5 больше не компенсируют друг друга
2. **Сильнее штрафует большие промахи.** ошибка в 2 раза больше даёт вклад в 4 раза больше — модель старается избегать грубых промахов
3. **Гладкая функция.** производная есть всюду, что критично для градиентного спуска

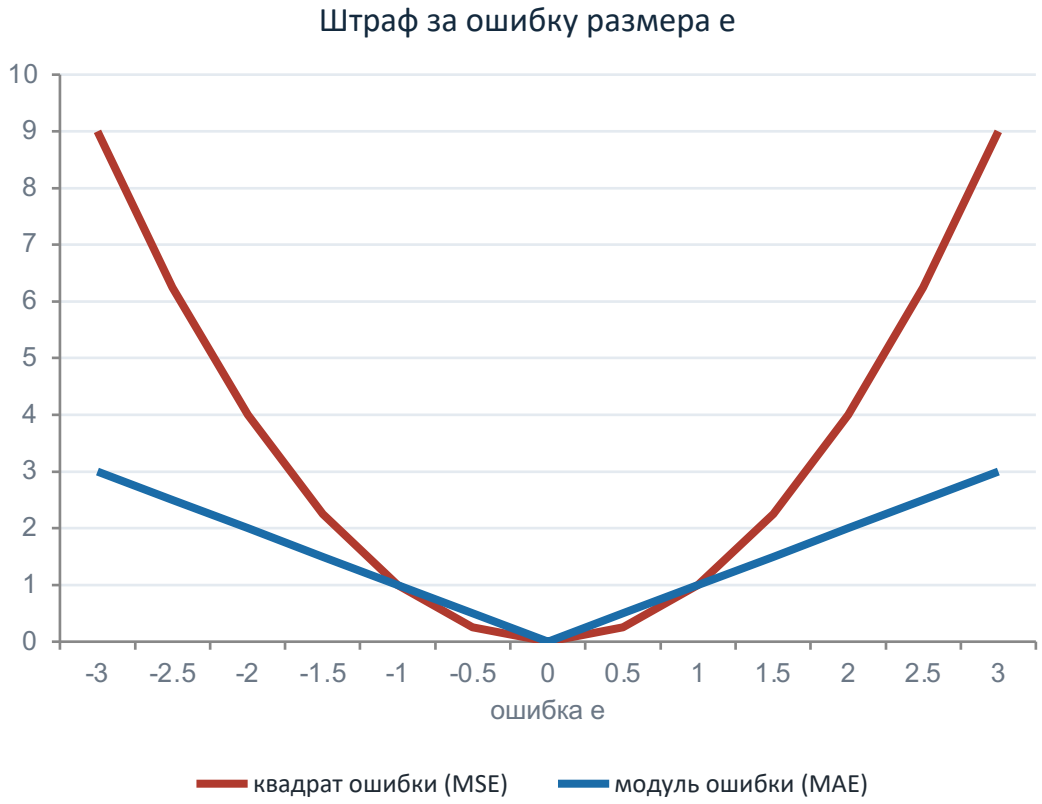
MAE — средняя абсолютная ошибка

Mean Absolute Error

$$\mathrm{MAE}(a, X) = \frac{1}{l}\sum_{i=1}^{l}\left|a(x_i) - y_i\right|$$

Чем отличается от MSE: растёт линейно, а не квадратично. Большой промах для MAE — это просто большой промах, а не катастрофа.

MAE тоже измеряется в единицах ответа — отдельный корень не нужен.



Где MSE подводит

Один выброс перетягивает всю модель

Пять почти одинаковых домов, но у пятого в базе опечатка — лишний ноль в цене:

Дом	1	2	3	4	5 (опечатка)
Цена y, млн ₽	2.0	2.1	1.9	2.0	10.0

Если минимизировать MSE

константный прогноз = среднее = 3.6

Ни один нормальный дом столько не стоит: выброс утащил прогноз вверх более чем на полтора миллиона.

Если минимизировать MAE

константный прогноз = медиана = 2.0

Выброс учтён, но не задаёт ответ. MAE устойчив к выбросам — это его главное преимущество.

Оптимумы MSE и MAE

Предположим, что на объектах с одинаковым признаковым описанием могут быть разные ответы. Тогда на всех таких объектах модель обязана выдать одно и то же число — какое именно, зависит от функции потерь.

Теорема

Пусть даны l объектов с одинаковым признаковым описанием и значениями целевой переменной $y_1, \ldots, y_l$. Тогда:

1. Оптимум MSE достигается на среднем значении ответов: $$\alpha_{\text{MSE}} = \frac{1}{l}\sum_{i=1}^{l} y_i$$

2. Оптимум MAE достигается на медиане ответов: $$\alpha_{\text{MAE}} = \text{median}\,\{y_1, \ldots, y_l\}$$

Оптимум MSE — среднее значение

Доказательство первой части теоремы

Шаг 1. Все l объектов одинаковые, поэтому модель выдаёт на них одно и то же число a. Ищем a, при котором ошибка минимальна:

$$L(a) = \frac{1}{l}\sum_{i=1}^{l}(y_i - a)^2 \;\longrightarrow\; \min_a$$

Шаг 2. Раскроем скобки. Получится парабола относительно a с ветвями вверх (коэффициент при a^2 равен 1 > 0), у неё ровно один минимум:

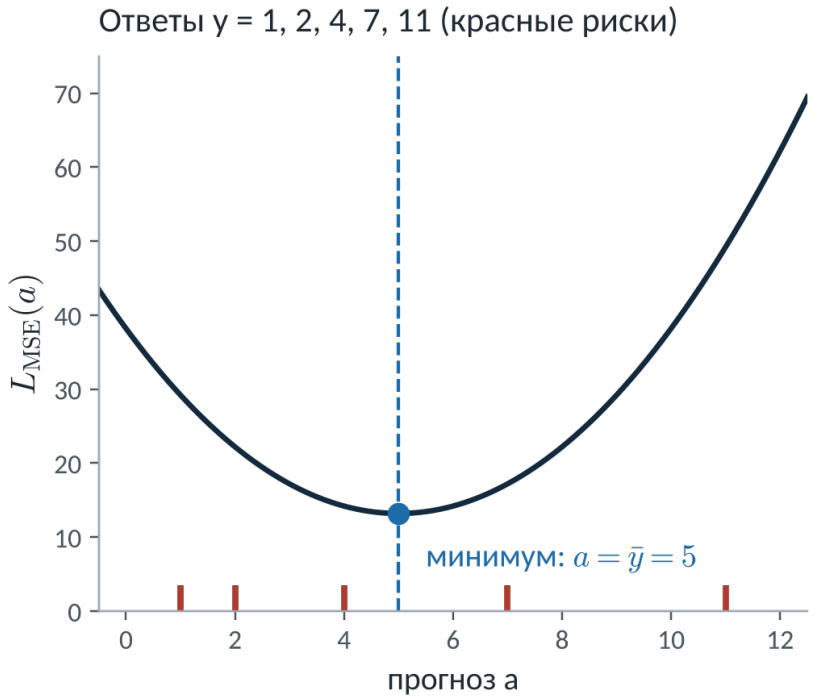
$$L(a) = a^2 - 2a \cdot \frac{1}{l}\sum_{i=1}^{l} y_i + \frac{1}{l}\sum_{i=1}^{l} y_i^2$$

Шаг 3. Приравняем производную к нулю. Вторая производная L″(a) = 2 > 0, поэтому найденная точка — минимум:

$$L'(a) = -\frac{2}{l}\sum_{i=1}^{l}(y_i - a) = 2\Big(a - \frac{1}{l}\sum_{i=1}^{l} y_i\Big) = 0$$

Шаг 4. Значит, оптимум MSE — среднее ответов:

$$a^* = \frac{1}{l}\sum_{i=1}^{l} y_i = \bar{y}$$



Без производных: $L(a) = \underbrace{\frac{1}{l}\sum_{i=1}^{l}(y_i - \bar{y})^2}_{\text{const}} + \underbrace{(a - \bar{y})^2}_{\geq 0}$ первое слагаемое от a не зависит, а второе ≥ 0 и равно нулю только при a = ȳ.

Оптимум MAE — медиана

Доказательство второй части теоремы

Шаг 1. Снова ищем одно число a. У модуля нет производной в нуле, поэтому будем рассуждать без производных:

$$L(a) = \frac{1}{l}\sum_{i=1}^{l} |y_i - a| \longrightarrow \min_a$$

Шаг 2. Упорядочим ответы по возрастанию: $y_{(1)} \le y_{(2)} \le \cdots \le y_{(l)}$

Шаг 3. Сдвинем a вправо на маленькое δ > 0, не перескакивая через точки. До каждой точки справа от a расстояние уменьшится на δ, до каждой точки слева (или в самой a) — увеличится на δ. Пусть n_L — число ответов ≤ a, n_R — число ответов > a. Тогда:

$$L(a+\delta) - L(a) = \frac{\delta}{l}\left(n_L - n_R\right)$$

Шаг 4. Пока слева точек меньше, чем справа, сдвиг вправо уменьшает ошибку; если слева больше — выгодно сдвигаться влево. Остановиться можно только там, где слева и справа поровну, — в медиане:

$$a^* = \operatorname{median}\{y_1, \ldots, y_l\}$$

При чётном l минимум — весь отрезок между двумя средними ответами.



Наклон на каждом участке равен $(n_L - n_R) / l$ и меняет знак ровно в медиане.

Именно поэтому в примере с домами MSE дал 3.6 (среднее), а MAE — 2.0 (медиану): среднее чувствительно к одному большому значению, медиана — нет.

Квантильная регрессия

Функция потерь, которая штрафует промахи вверх и вниз по-разному

$$Q(a, X) = \sum_{i=1}^{l} \rho_\tau\big(y_i - a(x_i)\big)$$

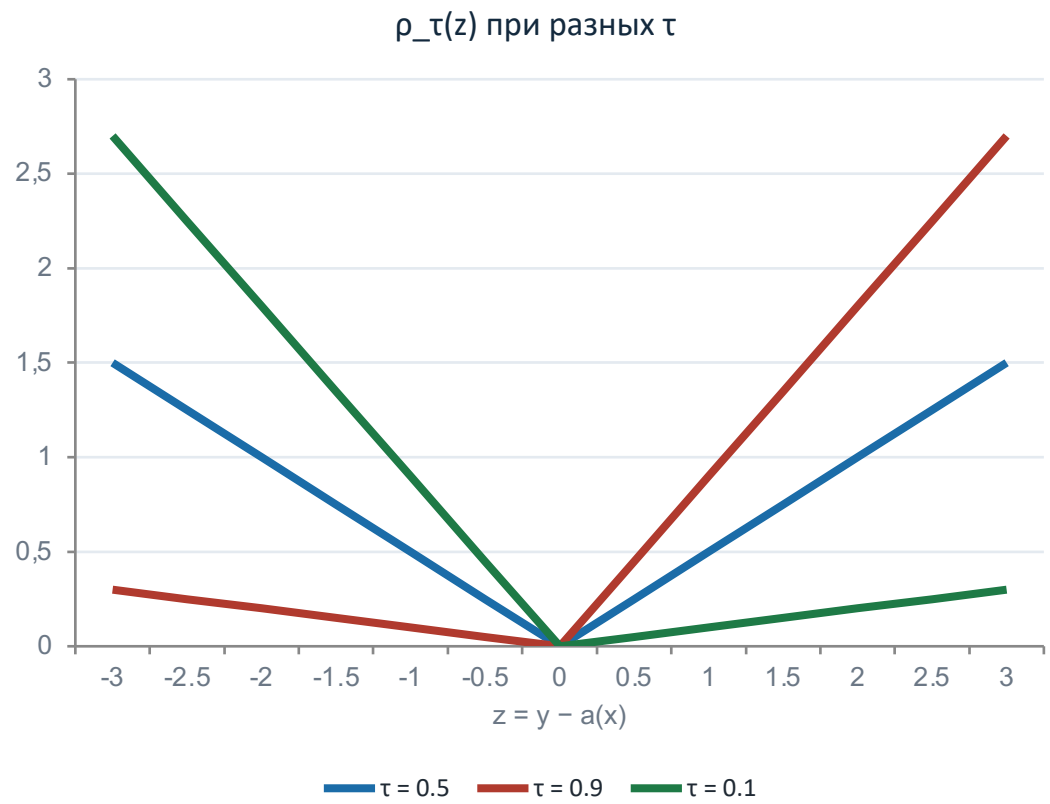
где

$$\rho_\tau(z) = (\tau - 1)[z < 0]\, z + \tau[z \geqslant 0]\, z$$

Параметр τ ∈ [0; 1].

Чем больше τ, тем сильнее штрафуем за занижение прогноза.

При τ = 0.5 получается обычный MAE (с точностью до множителя).



Вероятностный смысл квантильных потерь

Теорема

Пусть в каждой точке $x \in X$ (пространство объектов) задано распределение $p(y|x)$ на ответах для данного объекта. Тогда оптимизация функции потерь $\rho_\tau(z)$ даёт алгоритм $a(x)$, приближающий τ-квантиль распределения ответов в каждой точке $x \in X$.



Зачем это нужно на практике

Склад и закупки	занижение спроса стоит дороже завышения: пустая полка — потерянные продажи. Берём $\tau \approx 0.9$ и прогнозируем «с запасом»
Сроки доставки	обещать клиенту медианный срок рискованно. Обещают верхнюю квантиль — её выдерживают в 90 % случаев
Прогноз интервала	обучив две модели с $\tau = 0.1$ и $\tau = 0.9$, получаем не точку, а коридор, в который ответ попадает в 80 % случаев

Как выбирать функцию потерь

Функция потерь	Что оптимизирует	Когда брать
MSE	среднее ответов	данные чистые, большие промахи особенно нежелательны
MAE	медиану ответов	в данных есть выбросы или тяжёлые хвосты
Квантильная ρ_τ	τ-квантиль ответов	ошибки вверх и вниз стоят по-разному

Главная мысль

Функция потерь — это не техническая деталь, а формулировка того, что для нас значит «ошибиться». Она должна приходить из задачи, а не из привычки.

3

Особенности применения

Что делать, когда признаки не числовые или влияют не монотонно

О применимости линейной модели

Пример

Предположим, что мы хотим предсказать стоимость дома y по его площади x_1, количеству комнат x_2, району x_3 и удалённости от МКАД x_4.

$$a(x) = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4$$



С какими проблемами столкнемся?

О применимости линейной модели

Пример

Предположим, что мы хотим предсказать стоимость дома y по его площади x_1, количеству комнат x_2, району x_3 и удалённости от МКАД x_4.

$$a(x) = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4$$



Проблема №1

Район x_3 — это не число, а название: Мамыри, Дудкино, Барвиха…

Проблема №2

Удалённость от МКАД x_4 влияет на стоимость не монотонно.

Проблема №1: район - категориальный признак

Первое решение — занумеровать районы. Мамыри = 1, Дудкино = 2, Барвиха = 3.

$$a(x) = \cdots + w_3 \cdot x_3$$

Хороший ли подход?

Проблема №1: район - категориальный признак

Первое решение — занумеровать районы. Мамыри = 1, Дудкино = 2, Барвиха = 3. Так делать нельзя.

$$a(x) = \cdots + w_3 \cdot x_3$$

Что при должно выполняться (что не так):

- районы упорядочены: Барвиха «больше» Дудкина, а Дудкино «больше» Мамырей;
- расстояния между ними одинаковы: переход 1 → 2 меняет цену ровно так же, как 2 → 3;
- эффект линеен: район № 10 влияет на цену в десять раз сильнее района № 1.

Ни одно из этих утверждений про районы не верно. Модель выучит несуществующий порядок и будет ошибаться.

One-hot encoding (OHE)

Решение проблемы №1: как строятся новые признаки

Создаём новые числовые столбцы, каждый из которых является индикатором района.

Район
Дудкино
Барвиха
Мамыри
…
Барвиха



Мамыри	Дудкино	Барвиха
0	1	0
0	0	1
1	0	0
…	…	…
0	0	1

Один столбец на каждое значение категории. В каждой строке ровно одна единица.

1. Находим все значения

Смотрим, какие районы вообще встречаются в данных: Мамыри, Дудкино, Барвиха.

2. Заводим индикаторы

Для каждого района — свой столбец: $x_{\text{Мамыри}} = 1$, если дом в Мамырях, иначе 0.

3. Убираем исходный столбец

Название района больше не нужно: модель видит только числовые столбцы из 0 и 1.

Почему OHE решает проблему

Решение проблемы №1: что видит модель

Подставим новые признаки в линейную модель:

$$a(x) = w_0 + w_1 x_1 + w_2 x_2 + w_{31} x_{\text{Мамыри}} + w_{32} x_{\text{Дудкино}} + w_{33} x_{\text{Барвиха}} + w_4 x_4$$

У каждого дома ровно один индикатор равен 1, поэтому от района в прогнозе остаётся одно слагаемое:

Дом в Мамырях

$x_{\text{Мамыри}} = 1$, остальные индикаторы = 0

$a(x) = \ldots + w_{31} + \ldots$

Дом в Дудкино

$x_{\text{Дудкино}} = 1$, остальные индикаторы = 0

$a(x) = \ldots + w_{32} + \ldots$

Дом в Барвихе

$x_{\text{Барвиха}} = 1$, остальные индикаторы = 0

$a(x) = \ldots + w_{33} + \ldots$

Нумерация районов

Вклад района: $w_3 \cdot 1$, $w_3 \cdot 2$ или $w_3 \cdot 3$ — один вес на все районы. Порядок районов и равные шаги между ними заданы заранее.

One-hot encoding

Вклад района: w_{31}, w_{32} или w_{33} — у каждого района свой вес. Модель сама выучит, например, +0.5, +1.2 и +9 млн ₽: порядок и расстояния берутся из данных.

В коде: pd.get_dummies(df, columns=['district']) или sklearn.preprocessing.OneHotEncoder

Две технические оговорки про OHE

1. Линейная зависимость столбцов (dummy variable trap)

Сумма всех индикаторных столбцов тождественно равна единице — то есть в точности равна фиктивному столбцу x_0. Матрица X оказывается вырожденной, и аналитическая формула, которую мы выведем дальше, перестаёт работать. Лечится удалением одного столбца (drop_first) или регуляризацией.

2. Категории с большим числом значений

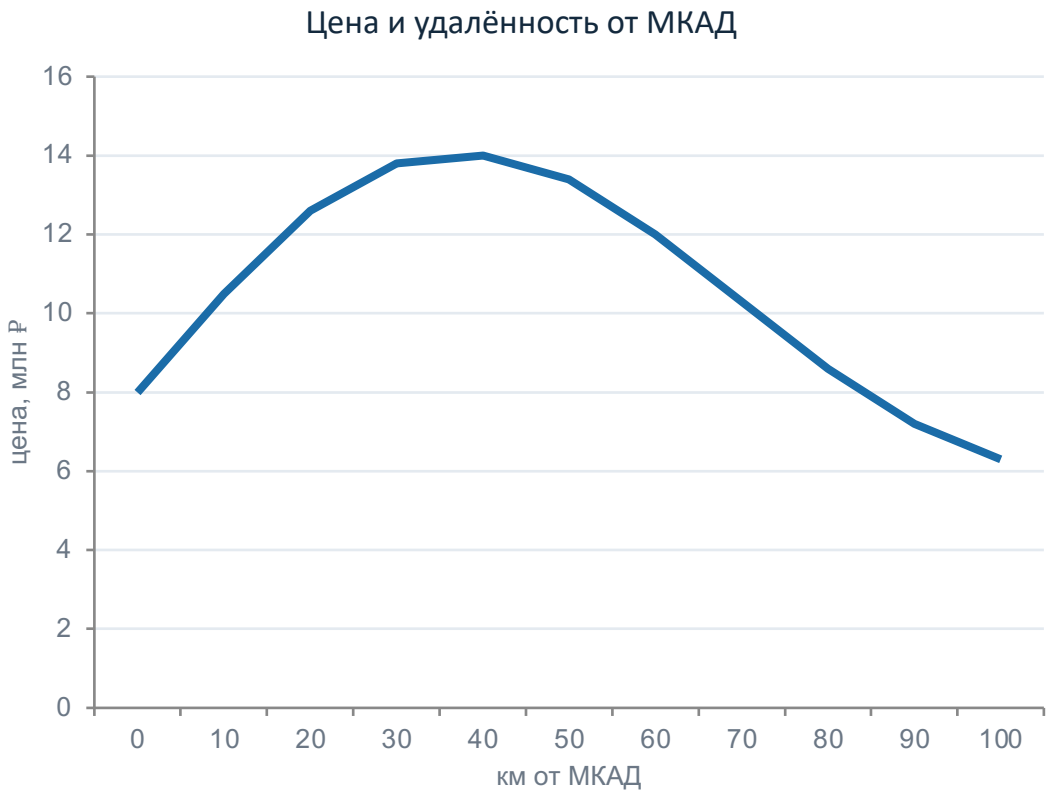
Если районов не три, а три тысячи, OHE добавит три тысячи столбцов, в каждом из которых почти везде нули. Модель станет огромной, а по редким районам данных всё равно не хватит. В таких случаях используют группировку редких категорий или счётчики (target encoding).

Проблема №2: немонотонное влияние признака

Удалённость от МКАД влияет на стоимость дома не монотонно: у самой кольцевой — шумно и грязно, очень далеко — неудобно добираться, а оптимум где-то посередине.

Почему это ломает модель

Слагаемое $w_4 \cdot x_4$ умеет только одно: равномерно повышать или равномерно понижать прогноз с ростом x_4. Изобразить «сначала вверх, потом вниз» оно не способно ни при каком весе.



Как быть?

Бинаризация (разбиение на бины)

Решение проблемы №2

Разобьём диапазон значений на интервалы и сделаем из каждого интервала отдельный индикаторный признак:

x[0;10)	= 1, если дом ближе 10 км от МКАД, иначе 0
x[10;30)	= 1, если дом в 10–30 км от МКАД, иначе 0
x[30;50)	= 1, если дом в 30–50 км от МКАД, иначе 0
x≥50	= 1, если дом дальше 50 км от МКАД, иначе 0

$$a(x) = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_{41} x_{[0;10)} + w_{42} x_{[10;30)} + w_{43} x_{[30;50)} + w_{44} x_{\geqslant 50}$$

У каждого интервала — свой вес, поэтому кривая любой формы теперь воспроизводима ступеньками.

Важный вывод

Линейная модель линейна по весам, а не по исходным признакам.

Признаки можно преобразовывать как угодно — модель останется линейной, а значит, сохранит и аналитическое решение, и быстрое обучение:

- **OHE —** категории → индикаторы
- **Бинаризация —** числовой признак → интервалы
- **Логарифм —** $log(x)$ вместо x при сильном разбросе
- **Степени —** x^2, x^3 — полиномиальная регрессия
- **Произведения —** $x_1 \cdot x_2$ — учёт взаимодействий признаков

4 Аналитическое решение

Задача обучения в матричной форме

Соберём все объекты в матрицу X размера *l* × *(n+1)*, а ответы — в вектор *y* длины *l*. Тогда все прогнозы сразу — это *Xw*, а все остатки — *Xw* − *y*.

$$\frac{1}{l}\left\|Xw - y\right\|^2 \to \min_w$$

Обозначение	Что это	Размер
X	матрица «объекты × признаки», первый столбец — единицы	l × (n+1)
w	вектор весов, который мы ищем	(n+1) × 1
y	вектор истинных ответов	l × 1
Xw − y	вектор остатков на всех объектах сразу	l × 1

Сначала — самый простой случай

Один признак, два веса: прямая на плоскости

Прежде чем выводить общую формулу, посмотрим на случай одного признака.

$$a(x) = w_0 + w_1 x$$

Функция потерь — сумма квадратов остатков:

$$Q(w_0, w_1) = \sum_{i=1}^{l} \left(w_0 + w_1 x_i - y_i\right)^2$$

Это гладкая функция двух переменных, и она выпуклая. Значит, минимум единственный и находится там, где обе частные производные равны нулю.

Приравниваем производные к нулю

$$\frac{\partial Q}{\partial w_0} = 2\sum_{i=1}^{l}\big(w_0 + w_1 x_i - y_i\big) = 0$$

$$\frac{\partial Q}{\partial w_1} = 2\sum_{i=1}^{l}\big(w_0 + w_1 x_i - y_i\big)x_i = 0$$

Преобразуем:

$$l\,w_0 + w_1\sum_{i=1}^{l} x_i = \sum_{i=1}^{l} y_i$$

$$w_0\sum_{i=1}^{l} x_i + w_1\sum_{i=1}^{l} x_i^2 = \sum_{i=1}^{l} x_i y_i$$

Два уравнения, два неизвестных — решается единственное.

Готовые формулы для одномерного случая

Из первого уравнения получаем, что прямая проходит через «центр масс» выборки — точку со средними координатами:

$$w_0 = \bar{y} - w_1 \bar{x}$$

Подставив это во второе уравнение, получаем наклон:

$$w_1 = \frac{\sum_{i=1}^{l}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{l}(x_i - \bar{x})^2}$$

В числителе — выборочная ковариация x и y, в знаменателе — дисперсия x. То есть наклон прямой показывает, насколько согласованно признак и ответ отклоняются от своих средних.

Считаем на наших шести домах

Признак один — площадь

	1	2	3	4	5	6	среднее
x — площадь	35	45	55	62	78	95	61.67
y — цена	6.0	8.2	9.5	11.0	13.4	16.1	10.70

$$w_1 = \frac{399.2}{2411.3} \approx 0.1656$$

$$w_0 = 10.70 - 0.1656 \cdot 61.67 \approx 0.491$$

$$a(x) = 0.491 + 0.1656\,x$$

Проверка: для дома 62 м² модель даёт 0.491 + 0.1656 · 62 ≈ 10.76 млн ₽ при факте 11.0. RMSE такой модели ≈ 0.20 млн ₽ — вдвое хуже, чем у модели с двумя признаками.

В общем случае

Раскроем квадрат нормы (множитель *1/l* на точку минимума не влияет, опустим его):

$$Q(w) = \left\|Xw - y\right\|^2 = (Xw - y)^\mathsf{T}(Xw - y) = w^\mathsf{T}X^\mathsf{T}Xw - 2w^\mathsf{T}X^\mathsf{T}y + y^\mathsf{T}y$$

Дифференцируем по правилам матричного дифференцирования:

$$\nabla_w Q = 2X^\mathsf{T}Xw - 2X^\mathsf{T}y$$

В общем случае

Раскроем квадрат нормы (множитель *1/l* на точку минимума не влияет, опустим его):

$$Q(w) = \left\|Xw - y\right\|^2 = (Xw - y)^\mathsf{T}(Xw - y) = w^\mathsf{T}X^\mathsf{T}Xw - 2w^\mathsf{T}X^\mathsf{T}y + y^\mathsf{T}y$$

Дифференцируем по правилам матричного дифференцирования:

$$\nabla_w Q = 2X^\mathsf{T}Xw - 2X^\mathsf{T}y$$

Приравниваем градиент к нулю и получаем:

$$X^\mathsf{T}Xw = X^\mathsf{T}y$$

Если матрица X^TX обратима, домножаем слева на обратную к ней — и всё:

$$w = \left(X^\mathsf{T}X\right)^{-1}X^\mathsf{T}y$$

Аналитическое решение задачи МНК

Задача обучения линейной регрессии (в матричной форме):

$$\frac{1}{l}\left\|Xw - y\right\|^2 \to \min_w$$

Точное (аналитическое) решение:

$$w = \left(X^\top X\right)^{-1} X^\top y$$

Недостатки аналитической формулы

Дорого считать	обращение матрицы — операция сложности $O(n^3)$ от числа признаков. При n порядка десятков тысяч это неприемлемо, а в промышленных задачах признаков бывает и больше
Матрица может быть вырожденной	X^TX необратима, если признаки линейно зависимы: дубликат столбца, полный набор OHE-столбцов вместе с константой, признак «площадь в м²» рядом с «площадью в футах²»
…или плохо обусловленной	формально обратима, но почти вырождена. Тогда крошечное изменение данных даёт огромный скачок весов — модель становится неустойчивой и неинтерпретируемой
Работает только для MSE	стоит заменить среднеквадратичный функционал на MAE или квантильный — и аналитического решения, скорее всего, не будет вовсе