ММП, Huber loss и метрики качества регрессии



Елена Кантонистова
ekantonistova@hse.ru

НИУ ВШЭ

План лекции

1. Напоминание: функции потерь MSE и MAE
2. Почему MSE? Метод максимума правдоподобия и требования к данным
3. Huber loss — компромисс между MSE и MAE
4. Метрики качества регрессии

1

Напоминание

Как обучается линейная регрессия, функции потерь MSE и MAE и их оптимумы

Что значит «обучить модель»

Обучение линейной регрессии — минимизация среднеквадратичной ошибки по весам:

$$Q(a, X) = \frac{1}{l}\sum_{i=1}^{l}\big(a(x_i) - y_i\big)^2 = \frac{1}{l}\sum_{i=1}^{l}\big(\langle w, x_i\rangle - y_i\big)^2 \to \min_w$$

здесь l — количество объектов обучающей выборки

Что фиксировано

Данные: объекты $x_1, \ldots, x_l$ и их ответы $y_1, \ldots, y_l$. Мы их не меняем.

Что подбираем

Веса $w_0, w_1, \ldots, w_n$ — ровно $n + 1$ число. Это и есть «обучение».

Как убрать знак?

Два естественных способа

Модуль

$$\left|a(x_i) - y_i\right|$$

Честно измеряет расстояние.

Квадрат

$$\left(a(x_i) - y_i\right)^2$$

Тоже убирает знак, гладкий всюду, легко дифференцируется. Именно его берут по умолчанию.

Оба варианта рабочие. Дальше разберём каждый и увидим, что выбор зависит от того, как устроены ваши данные.

Где MSE подводит

Один выброс перетягивает всю модель

Пять почти одинаковых домов, но у пятого в базе опечатка — лишний ноль в цене:

Дом	1	2	3	4	5 (опечатка)
Цена y, млн ₽	2.0	2.1	1.9	2.0	10.0

Если минимизировать MSE

константный прогноз = среднее = 3.6

Ни один нормальный дом столько не стоит: выброс утащил прогноз вверх более чем на полтора миллиона.

Если минимизировать MAE

константный прогноз = медиана = 2.0

Выброс учтён, но не задаёт ответ. MAE устойчив к выбросам — это его главное преимущество.

Оптимумы MSE и MAE

Предположим, что на объектах с одинаковым признаковым описанием могут быть разные ответы. Тогда на всех таких объектах модель обязана выдать одно и то же число — какое именно, зависит от функции потерь.

Теорема

Пусть даны l объектов с одинаковым признаковым описанием и значениями целевой переменной $y_1, \ldots, y_l$. Тогда:

1. Оптимум MSE достигается на среднем значении ответов: $\alpha_{\text{MSE}} = \frac{1}{l}\sum_{i=1}^{l} y_i$

2. Оптимум MAE достигается на медиане ответов: $\alpha_{\text{MAE}} = \text{median}\,\{y_1, \ldots, y_l\}$

2

Почему всё-таки чаще всего MSE?

Метод максимума правдоподобия: откуда квадрат берётся не из удобства, а из предположений о данных

Метод максимума правдоподобия на пальцах

Подбросили монетку 10 раз, выпало 7 орлов. Какова вероятность орла ***p*** у этой монетки?

Идея метода: перебрать все возможные p и выбрать то, при котором наблюдаемый результат наиболее вероятен.

$p = 0.1$	$p = 0.5$	$p = 0.7$	$p = 0.9$
вероятность увидеть 7 орлов	вероятность увидеть 7 орлов	вероятность увидеть 7 орлов	вероятность увидеть 7 орлов
0.000009	**0.117**	**0.267**	**0.057**
почти невозможно	*правдоподобно*	*самый вероятный вариант*	*снова маловероятно*



$$P(X = 7) = C_{10}^{7} \cdot 0.7^{7} \cdot 0.3^{3}$$

Победил $p = 0.7$ — ровно доля орлов в эксперименте. Это и есть оценка максимального правдоподобия.

Рецепт метода максимума правдоподобия

1. **Придумать вероятностную модель данных**
   записать, с какой вероятностью появляется наблюдаемый ответ, если параметр равен заданному значению

2. **Записать правдоподобие выборки**
   перемножить вероятности всех наблюдений — это законно, если объекты независимы

3. **Максимизировать по параметру**
   найти то значение параметра, при котором произведение максимально

4. **Перейти к логарифму**
   логарифм монотонен, максимум не сдвигается, а произведение превращается в сумму — считать становится проще

Вероятностная постановка

Даже если целевая переменная линейно зависит от признаков, идеальной модели не существует: реальные ответы будут отличаться от предсказаний, поэтому мы пишем

$$y \approx \langle w, x \rangle$$

Неидеальность прогноза можно объяснить неполнотой данных или шумом в них. Тогда формула переписывается со знаком равенства:

$$y = \langle w, x \rangle + \varepsilon$$

где ε — шум в данных.

Предположение о шуме

Шум в данных обычно имеет некоторое распределение. В большинстве реальных задач считается, что

$$\varepsilon \sim N(0,\ \sigma^2)$$

Отсюда получаем, что

$$y \sim N\big(\langle w, x\rangle,\ \sigma^2\big)$$

При фиксированных признаках x ответ y не предопределён — он «размазан» вокруг прямой $\langle w, x\rangle$ колоколом нормального распределения. Центр колокола задаёт модель, ширину — уровень шума σ.

Что значит «подобрать оптимальные веса»

$$p(y \mid x, w) \sim N\big(\langle w, x\rangle,\ \sigma^2\big)$$

Это означает, что вероятность наблюдать *y* при данных значениях *x* задаётся нормальной плотностью с центром в прогнозе модели.

Мы хотим подобрать такой вектор *w*, при котором вероятность наблюдать имеющиеся ответы *y* максимальна.

Запишем это желание сразу для всех объектов выборки — в предположении, что объекты независимы:

$$p(\mathbf{y} \mid X, w) = p(y_1 \mid x_1, w) \cdot p(y_2 \mid x_2, w) \cdot \ldots \cdot p(y_l \mid x_l, w) \to \max_w$$

Функция правдоподобия

Величина $\boldsymbol{p(y \mid X, w)}$ называется функцией правдоподобия (или правдоподобием) выборки.

Важно понимать, что это функция не от данных, а от весов

- Данные уже собраны и зафиксированы: y и X мы не меняем. Меняется только w — и для каждого набора весов мы можем спросить: «а насколько вероятно было увидеть именно такие ответы, если бы истинная модель имела эти веса?»

- Тот набор весов, который даёт наибольшую вероятность, мы и объявляем ответом. Ровно как с монеткой, где мы перебирали p.

ММП для линейной регрессии

Модель данных с некоррелированным гауссовским шумом:

$$y_i = \langle w, x_i \rangle + \varepsilon_i, \qquad \varepsilon_i \sim N(0,\ \sigma^2), \qquad i = 1, \ldots, l$$

Тогда $y_i \sim N\big(\langle w, x_i \rangle,\ \sigma^2\big), \qquad i = 1, \ldots, l$

Метод максимума правдоподобия (ММП):

$$L(y_1, \ldots, y_l \mid w) = \prod_{i=1}^{l} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2\sigma^2}\big(y_i - \langle w, x_i \rangle\big)^2\right) \to \max_w$$

Логарифмируем — и получаем МНК

Произведение экспонент неудобно. Возьмём логарифм со знаком минус: максимум превратится в минимум, произведение — в сумму, а экспонента исчезнет.

$$-\ln L(y_1, \ldots, y_l \mid w) = \text{const} + \frac{1}{2\sigma^2} \sum_{i=1}^{l} \big(y_i - \langle w, x_i \rangle\big)^2 \to \min_w$$

Константа и множитель $1/(2\sigma^2)$ не зависят от w — на точку минимума они не влияют. Остаётся ровно сумма квадратов остатков.

В данном случае ММП совпадает с МНК

МНК — метод наименьших квадратов, англ. OLS (ordinary least squares).

Какие предположения стоят за MSE

Требования к данным, при которых ММП приводит именно к MSE

1. **Линейность в среднем**
   $E(y|x) = \langle w, x \rangle$: в среднем ответ действительно линейно зависит от признаков

2. **Независимость объектов**
   иначе правдоподобие выборки нельзя записать как произведение вероятностей

3. **Нормальный шум**
   $\varepsilon \sim N(0, \sigma^2)$: симметричный, большие отклонения крайне редки — выбросов почти нет

4. **Нулевое среднее шума**
   модель не ошибается систематически в одну сторону

5. **Одинаковый разброс**
   σ одна и та же для всех объектов и не зависит от x (гомоскедастичность)

Если всё выполнено

минимум MSE — это оценка максимального правдоподобия для w;

модель предсказывает условное среднее $E(y|x)$.

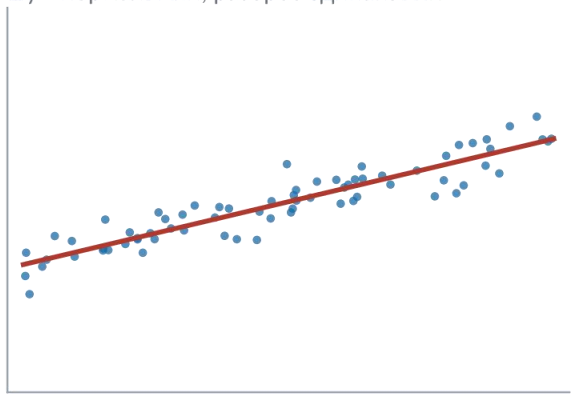
Если нет

MSE всё ещё можно минимизировать, но это уже не ММП-оценка: выбросы и неравный шум будут тянуть модель.

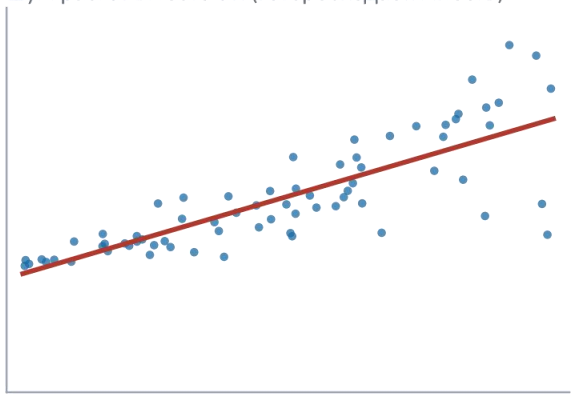
Как выглядят нарушения

Красная линия — модель, обученная на MSE

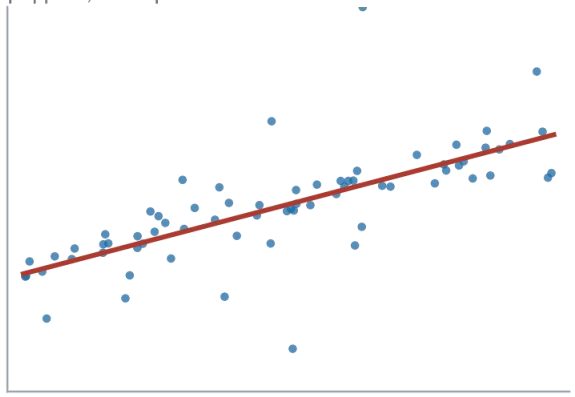
Всё в порядке
шум нормальный, разброс одинаковый



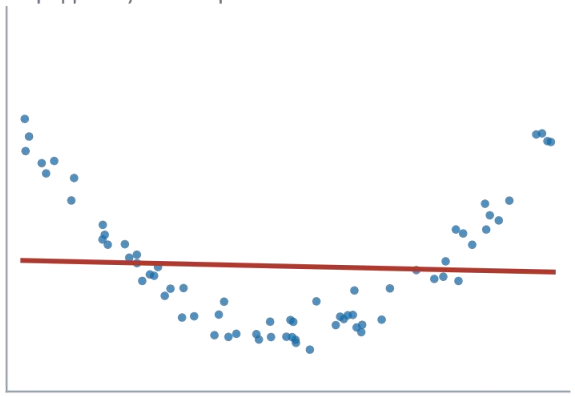
Разный разброс
шум растёт вместе с x (гетероскедастичность)



Выбросы, тяжёлые хвосты
редкие, но огромные отклонения



Зависимость нелинейна
в среднем y — не прямая от x



Разный разброс

шумные объекты получают в MSE такой же вес, как точные → взвешенный МНК или логарифм ответа

Выбросы, тяжёлые хвосты

несколько огромных отклонений перетягивают прямую → MAE или Huber loss

Нелинейная зависимость

это проблема модели, а не функции потерь → преобразовать признаки (как с удалённостью от МКАД)

Шум с тяжёлыми хвостами: распределение Лапласа

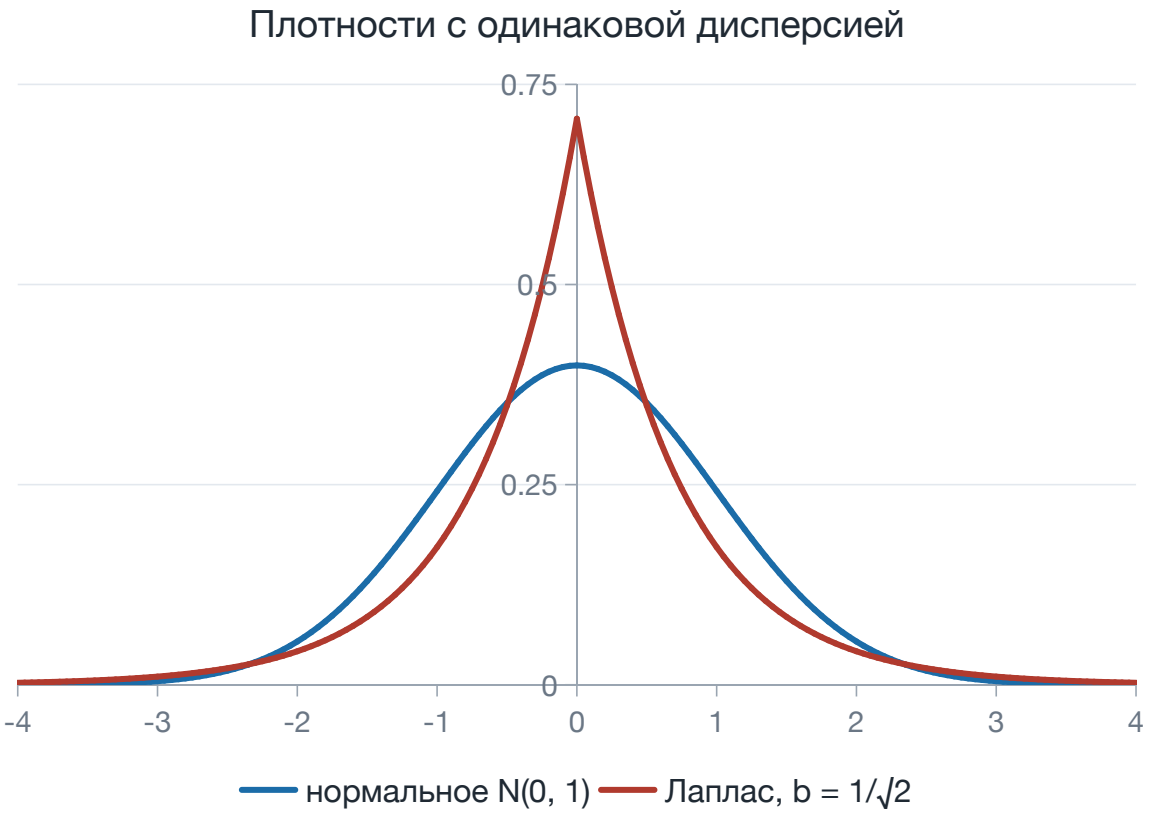
Что, если большие отклонения — не такая уж редкость?

$$p(\varepsilon) = \frac{1}{2b}\exp\left(-\frac{|\varepsilon|}{b}\right)$$

$b > 0$ — масштаб. Плотность убывает как $\exp(-|\varepsilon|)$, а не как $\exp(-\varepsilon^2)$, поэтому хвосты у распределения «тяжелее».

Отклонение	Нормальное	Лаплас
больше 2σ	4.6 %	5.9 %
больше 3σ	0.27 %	1.4 %
больше 4σ	0.006 %	0.35 %

оба распределения — с нулевым средним и дисперсией $\sigma^2 = 1$



При шуме Лапласа отклонение больше 4σ встречается примерно в 50 раз чаще, чем при нормальном. Выбросы для такой модели — ожидаемая часть данных.

ММП с шумом Лапласа приводит к MAE

Повторяем тот же рецепт — меняем только распределение шума

Модель данных:

$$y_i = \langle w, x_i \rangle + \varepsilon_i, \qquad \varepsilon_i \sim \text{Laplace}(0, b), \qquad i = 1, \ldots, l$$

Правдоподобие выборки (объекты независимы):

$$L(y_1, \ldots, y_l \mid w) = \prod_{i=1}^{l} \frac{1}{2b} \exp\left(-\frac{|y_i - \langle w, x_i \rangle|}{b}\right) \to \max_w$$

Берём логарифм со знаком минус — произведение превращается в сумму:

$$-\ln L(y_1, \ldots, y_l \mid w) = l \ln(2b) + \frac{1}{b} \sum_{i=1}^{l} |y_i - \langle w, x_i \rangle| \to \min_w$$

Слагаемое $l \ln(2b)$ и множитель $1/b$ от w не зависят. Остаётся:

$$\frac{1}{l} \sum_{i=1}^{l} |y_i - \langle w, x_i \rangle| \to \min_w$$

При шуме Лапласа ММП совпадает с минимизацией MAE

Требования к данным: MSE и MAE

Что должно выполняться, чтобы функция потерь давала оценку максимального правдоподобия

Требование	MSE	MAE
Связь *y* и *x*	в среднем линейна: $E(y\|x) = \langle w, x \rangle$	по медиане линейна: $\text{median}(y\|x) = \langle w, x \rangle$
Объекты	независимы	независимы
Распределение шума	нормальное $N(0, \sigma^2)$	Лапласа $\text{Laplace}(0, b)$
Разброс шума	одинаковый σ у всех объектов	одинаковый b у всех объектов
Выбросы	почти невозможны, сильно портят модель	ожидаемы, влияют слабо
Что предсказывает модель	условное среднее	условную медиану

Если шум симметричный, условные среднее и медиана совпадают — MSE и MAE оценивают одну и ту же прямую. Разница в том, как они переносят выбросы: MSE точнее на «чистых» нормальных данных, MAE устойчивее при тяжёлых хвостах.

Что мы на самом деле выяснили

Функция потерь = $-\ln$(плотность шума) + константа. Выбирая функцию потерь, мы выбираем предположение о данных.

Предположение о шуме	$-\ln p(\varepsilon)$ без констант	Функция потерь
нормальный $N(0, \sigma^2)$	$\varepsilon^2/(2\sigma^2)$	MSE
Лапласа — тяжёлые хвосты	$\lvert\varepsilon\rvert/b$	MAE
асимметричный Лапласа	$\rho_\tau(\varepsilon)/b$	квантильная
нормальный в центре, «лапласовы» хвосты	$L_\delta(\varepsilon)$	**Huber loss — о нём дальше**

Вывод: если в данных есть существенные выбросы, предположение о нормальном шуме неадекватно. MSE будет большой, а модель — плохо соответствовать реальности.

3

Huber loss

Функция потерь, которая на маленьких ошибках ведёт себя как MSE, а на больших — как MAE

Huber loss

Квадрат для маленьких ошибок, модуль — для больших

$$L_\delta(z) = \begin{cases} \frac{1}{2}\, z^2, & |z| \le \delta, \\ \delta\left(|z| - \frac{1}{2}\,\delta\right), & |z| > \delta, \end{cases}$$

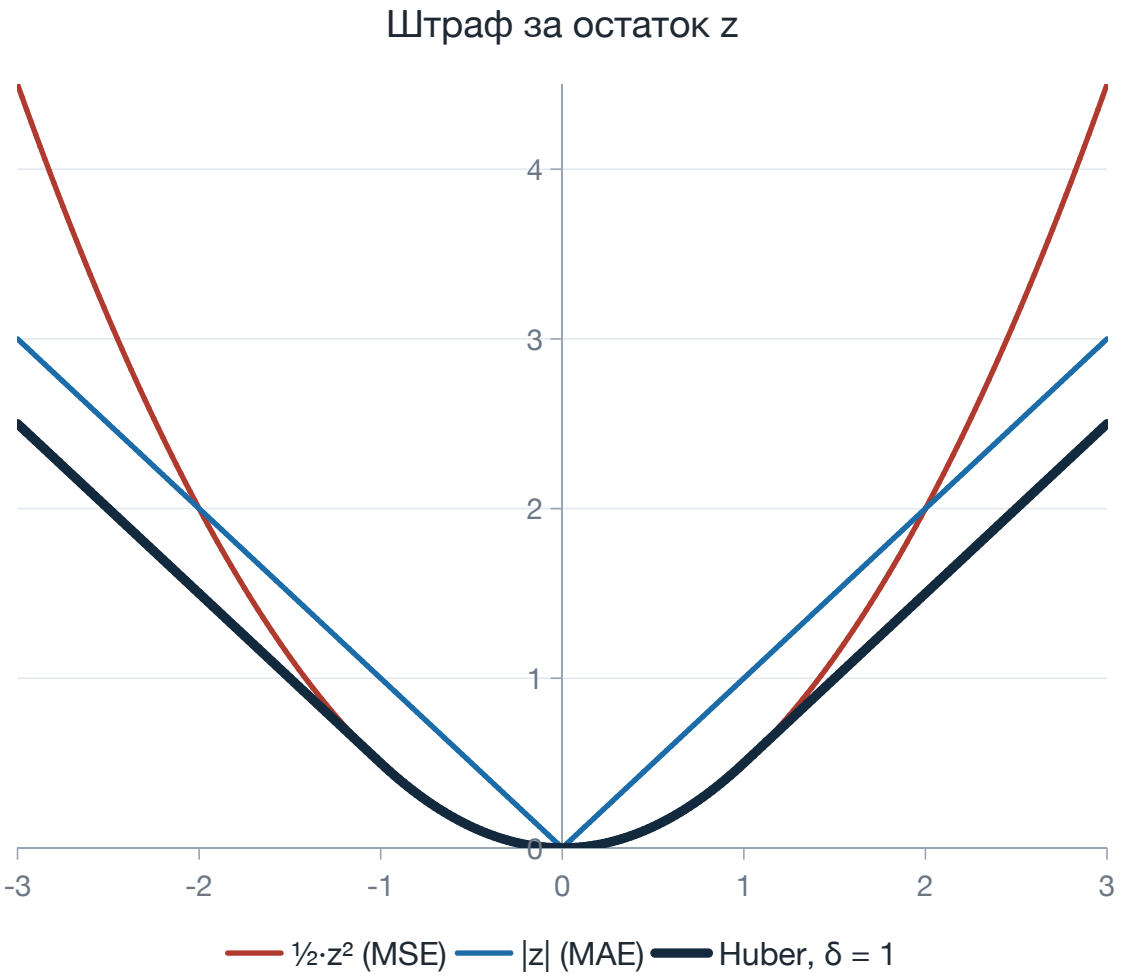
$z = y - a(x)$ — остаток, $\delta > 0$ — порог (гиперпараметр).

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^{l} L_\delta\big(y_i - a(x_i)\big) \;\to\; \min$$

|z| ≤ δ: квадрат, как в MSE;

|z| > δ: растёт линейно, как MAE;

|z| = δ: куски склеены гладко — совпадают и значения, и наклон.



Чем хорош Huber loss

Берёт лучшее у MSE и MAE

Маленькие ошибки — как MSE

вблизи нуля функция гладкая, без излома; на «чистых» данных оценка почти так же точна, как у MSE

Большие ошибки — как MAE

штраф растёт линейно, поэтому один выброс не перетягивает модель: его «тяга» ограничена величиной δ

δ — граница «нормальной» ошибки

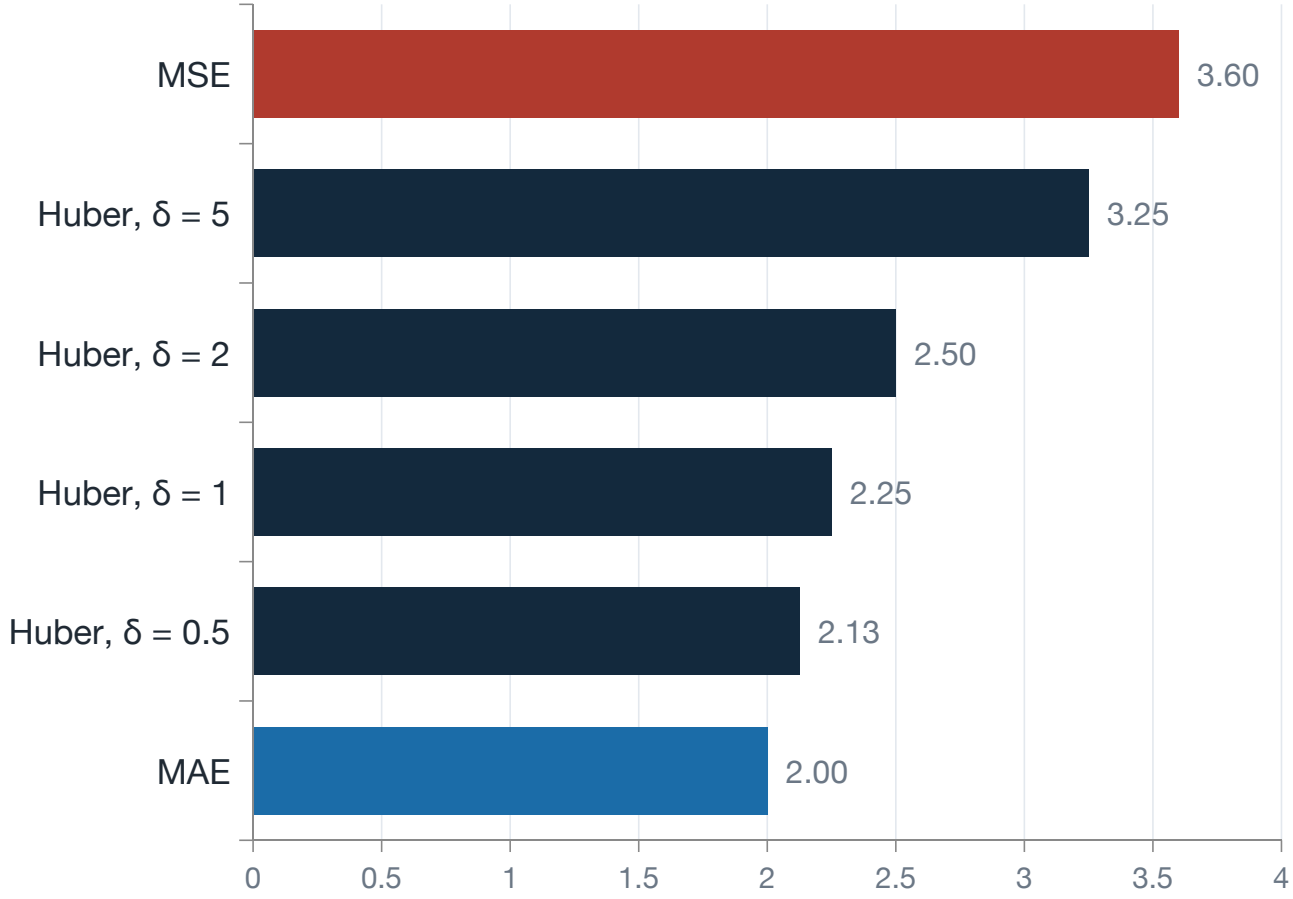
$\delta \to \infty$: Huber превращается в MSE (с множителем $1/2$). $\delta \to 0$: ведёт себя как MAE (с точностью до масштаба)

Интуиция. Ошибки меньше δ считаем обычным шумом и наказываем квадратично. Ошибки больше δ — подозрительными: наказываем мягче, линейно.

Huber loss — не единственный компромисс: есть гладкие аналоги (pseudo-Huber, log-cosh), но идея у них та же.

Пример: снова пять домов

Цены 2.0, 2.1, 1.9, 2.0 и выброс 10.0 млн ₽ — какой константный прогноз даёт каждая функция потерь



Что видно

по мере уменьшения δ Huber плавно переходит от среднего (MSE, 3.6) к медиане (MAE, 2.0).

Почему так

выброс отстоит от прогноза больше чем на δ, поэтому тянет ответ с постоянной силой δ, а не пропорционально ошибке. При $\delta = 1$ прогноз 2.25 вместо 3.6.

Как выбрать δ

И где взять Huber loss на практике

1. **По смыслу задачи**
   δ измеряется в тех же единицах, что и ответ: ошибки меньше δ считаем нормальным шумом. Например, для цен квартир можно взять $\delta = 0.5$ млн ₽

2. **По данным**
   ориентироваться на типичный размер остатков или подобрать δ на кросс-валидации

3. **В sklearn**
   HuberRegressor(epsilon=1.35): порог задаётся в единицах масштаба шума, который модель оценивает сама. 1.35 — классический выбор: на нормальных данных почти не уступает MSE, а выбросы гасит

Связь с ММП. Huber loss — это −ln плотности распределения, которое в центре похоже на нормальное, а на хвостах — на распределение Лапласа. Huber предполагает: «шум в основном нормальный, но иногда бывают выбросы».

Как выбирать функцию потерь

Функция потерь	Что оптимизирует	Когда брать
MSE	среднее ответов	данные чистые, большие промахи особенно нежелательны
MAE	медиану ответов	в данных есть выбросы или тяжёлые хвосты
Huber	между медианой и средним	данные в основном чистые, но изредка бывают выбросы
Квантильная ρ_τ	τ-квантиль ответов	ошибки вверх и вниз стоят по-разному

Главная мысль

Функция потерь — это не техническая деталь, а формулировка того, что для нас значит «ошибиться». Она должна приходить из задачи, а не из привычки.

4

Метрики качества регрессии

Как оценить уже обученную модель и сравнить модели между собой

Функция потерь и метрика качества

Функция потерь (функционал ошибки)

функция, которую минимизируют при обучении, чтобы найти веса модели

Метрика качества

функция, которой оценивают уже обученную модель

1. **Иногда это одна и та же функция**
   MSE часто используют и для обучения, и для оценки

2. **Но не обязательно**
   модель учат на MSE, а бизнес смотрит на MAPE или WAPE: от функции потерь нужна удобная оптимизация, от метрики — понятный смысл

3. **Метрику считают на новых данных**
   на отложенной выборке или на кросс-валидации, а не на тех объектах, на которых модель обучалась

Пример, на котором посчитаем все метрики

Модель «площадь + комнаты» из прошлой лекции на шести домах, цены в млн ₽

Дом	Факт y	Прогноз $a(x)$	Ошибка $a(x) - y$	|ошибка|	ошибка²	|ошибка| / y
1	6.0	6.12	+0.12	0.12	0.0144	2.00 %
2	8.2	8.10	−0.10	0.10	0.0100	1.22 %
3	9.5	9.48	−0.02	0.02	0.0004	0.21 %
4	11.0	11.05	+0.05	0.05	0.0025	0.45 %
5	13.4	13.26	−0.14	0.14	0.0196	1.04 %
6	16.1	16.21	+0.11	0.11	0.0121	0.68 %
среднее	**10.70**			**0.090**	**0.0098**	**0.93 %**

Последняя строка — это уже метрики: MAE = 0.090, MSE = 0.0098, MAPE = 0.93%.

Это обучающие данные: в реальной задаче метрики считают на тестовой выборке. Здесь они нужны, чтобы посчитать все метрики на одном примере.

MSE как метрика

Mean Squared Error — среднеквадратичная ошибка

$$\mathrm{MSE}(a, X) = \frac{1}{l}\sum_{i=1}^{l}\big(a(x_i) - y_i\big)^2$$

Плюсы

позволяет сравнивать модели между собой

подходит для контроля качества во время обучения

совпадает с функцией потерь линейной регрессии

Минусы

не сохраняет единицы измерения: если y в кг, то MSE — в кг^2

не ограничена сверху: по одному числу не понять, хорошо ли решена задача

чувствительна к выбросам

Шесть домов: MSE ≈ 0.0098 (млн ₽)^2. «Квадратные миллионы рублей» ничего не скажут заказчику.

RMSE

Root Mean Squared Error — корень из среднеквадратичной ошибки

$$\mathrm{RMSE}(a, X) = \sqrt{\frac{1}{l}\sum_{i=1}^{l}\big(a(x_i) - y_i\big)^2}$$

Плюсы

все плюсы MSE

в тех же единицах, что и ответ

минимизировать RMSE и MSE — одно и то же: корень монотонен

Минусы

не ограничена сверху: по одному числу не понять, хорошо ли решена задача

как и MSE, чувствительна к выбросам

Шесть домов: RMSE ≈ 0.099 млн ₽, то есть около 99 тыс. ₽.

MAE как метрика

Mean Absolute Error — средняя абсолютная ошибка

$$\mathrm{MAE}(a, X) = \frac{1}{l}\sum_{i=1}^{l}|a(x_i) - y_i|$$

Плюсы

в тех же единицах, что и ответ: «в среднем ошибаемся на столько-то»

менее чувствительна к выбросам, чем MSE и RMSE

Минусы

как функция потерь не дифференцируема в нуле (для метрики это неважно)

не ограничена сверху

не отличает много мелких ошибок от одной крупной

Шесть домов: MAE = 0.090 млн ₽, то есть 90 тыс. ₽.

RMSE и MAE вместе

Разница между ними подсказывает, есть ли крупные промахи

Модель	Ошибки на пяти объектах	MAE	RMSE
A	1, 1, 1, 1, 1	1.0	1.0
B	0, 0, 0, 0, 5	1.0	2.24

По MAE модели одинаковы, но у B один большой промах — и RMSE это видит.

Как читать

RMSE ≈ MAE — ошибки примерно одного размера;

RMSE заметно больше MAE — среди ошибок есть крупные промахи.

Шесть домов

RMSE = 0.099, MAE = 0.090 — почти равны: ошибки ровные, грубых промахов нет.

Хорошо это или плохо?

Абсолютные метрики нужно с чем-то сравнивать

RMSE = 99 тыс. ₽. Это много или мало?

Зависит от масштаба

для квартир за 10 млн ₽ это 1 % цены, для гаражей за 300 тыс. ₽ — треть цены.

Нужна точка отсчёта

самая простая модель — всегда предсказывать среднее $\bar{y}$. Её RMSE равна стандартному отклонению y.

Шесть домов: константа $\bar{y} = 10.7$ даёт RMSE $\approx$ 3.32 млн ₽, а наша модель — 0.099 млн ₽, примерно в 33 раза меньше.

Эту идею формализует коэффициент детерминации R^2.

Коэффициент детерминации R^2

Во сколько раз модель лучше константы

$$R^2(a, X) = 1 - \frac{\sum_{i=1}^{l} \big(a(x_i) - y_i\big)^2}{\sum_{i=1}^{l} \big(y_i - \bar{y}\big)^2}, \qquad \bar{y} = \frac{1}{l} \sum_{i=1}^{l} y_i$$

В числителе — ошибка модели, в знаменателе — ошибка константной модели $\bar{y}$. Поэтому R^2 можно переписать так:

$$R^2 = 1 - \frac{\mathrm{MSE}(a)}{\mathrm{MSE}(\bar{y})}$$

R^2 — доля дисперсии целевой переменной, которую объясняет модель.

Шесть домов: $R^2 = 1 - 0.0098 / 11.05 \approx 0.999$ — модель объясняет 99.9 % разброса цен.

Как читать R^2

$R^2 < 0$

хуже константы

$0 < R^2 < 1$

лучше константы

$R^2 = 1$

идеальная модель

$R^2 = 0$: как $\bar{y}$

$R^2 \leq 1$ всегда

равенство — только если модель не ошиблась ни на одном объекте

Снизу не ограничен

на тестовой выборке плохая модель легко получает $R^2 < 0$: она хуже, чем просто предсказывать среднее

«Хороший» R^2 зависит от задачи

в физическом эксперименте ждут 0.99, а в задачах про поведение людей и 0.3 может быть полезным результатом

Подвох R^2: число признаков

На обучающей выборке R^2 только растёт

Проблема

если добавить в модель любой признак — даже случайный шум, — R^2 на обучающей выборке не уменьшится: модели всегда разрешено поставить новому признаку нулевой вес.

Скорректированный R^2 штрафует за число признаков n (l — число объектов):

$$R^2_{\text{adj}} = 1 - \left(1 - R^2\right) \frac{l - 1}{l - n - 1}$$

Шесть домов, два признака: $R^2_{\text{adj}} = 1 - 0.00089 \cdot 5/3 \approx 0.9985$ — чуть меньше, чем $R^2 = 0.9991$.

Ещё одно ограничение

R^2 разных выборок не сравнивают: знаменатель зависит от разброса y в конкретной выборке.

MSLE

Mean Squared Logarithmic Error — среднеквадратичная логарифмическая ошибка

$$\mathrm{MSLE}(a, X) = \frac{1}{l}\sum_{i=1}^{l}\Big(\ln\big(a(x_i)+1\big) - \ln\big(y_i+1\big)\Big)^2$$

Только для $y \geq 0$

логарифм определён при $y + 1 > 0$

: подходит для цен, продаж, числа посещений

Штрафует относительную ошибку

10 → 20: штраф 0.42

1000 → 1010: штраф 0.0001

1000 → 2000: штраф 0.48

Занижение хуже завышения

факт $y = 100$:

прогноз 50 — штраф 0.47

прогноз 150 — штраф 0.16

MSLE — это MSE для преобразованного ответа $\ln(y + 1)$. Модель можно обучить на $\ln(y + 1)$ с обычной MSE, а потом вернуться к ответу через $\exp(\cdot) - 1$. Корень из MSLE называют RMSLE.

MAPE

Mean Absolute Percentage Error — средняя абсолютная процентная ошибка

$$\mathrm{MAPE}(a, X) = \frac{1}{l} \sum_{i=1}^{l} \frac{|y_i - a(x_i)|}{|y_i|}$$

MAPE измеряет относительную ошибку: MAPE = 0.16 означает, что модель в среднем ошибается на 16 % от фактического значения.

Плюсы

MAPE ≥ 0 и безразмерна

понятна бизнесу: «ошибаемся на 9 %»

можно сравнивать качество на рядах разного масштаба

Шесть домов

MAPE ≈ 0.0094: в среднем модель ошибается меньше чем на 1 % цены.

Но у MAPE есть серьёзные подводные камни →

Подводные камни MAPE

Нули и маленькие y

при $y = 0$ MAPE не определена, а при y, близких к нулю, одна ошибка взрывает всё среднее (продажи штучного товара, дни без продаж)

Несимметрична

$y = 10$, прогноз 20: ошибка 100 %

$y = 30$, прогноз 20: ошибка 33 %

промах одинаковый, а штраф в 3 раза разный. Занижение стоит не больше 100 %, завышение — сколько угодно

Тянет прогноз вниз

константа, оптимальная по MAPE, — медиана с весами $1/y$.

$y = 10,20,30,40,100$: среднее 40, медиана 30, а оптимум MAPE — 20

Модель, которую оптимизируют по MAPE, систематически занижает прогнозы. Для прогноза спроса это значит пустые полки.

SMAPE

Symmetric MAPE — попытка сделать MAPE симметричной

$$\mathrm{SMAPE}(a, X) = \frac{1}{l}\sum_{i=1}^{l}\frac{|y_i - a(x_i)|}{(|y_i| + |a(x_i)|)/2}$$

В знаменателе — среднее факта и прогноза. Проверим на том же примере:

Факт y	Прогноз	MAPE	SMAPE
10	20	1.00	0.67
30	20	0.33	0.40

Ошибки стали ближе друг к другу, но всё-таки не равны.

Диапазон

от 0 до 2 (0–200 %)

В знаменателе стоит сам прогноз: завышая его, можно уменьшить ошибку. Поэтому среди прогнозистов SMAPE считают неудачной метрикой — её легко «обмануть».

WAPE

Weighted Absolute Percentage Error — популярная замена MAPE в прогнозе спроса

$$\mathrm{WAPE}(a, X) = \frac{\sum_{i=1}^{l} |y_i - a(x_i)|}{\sum_{i=1}^{l} |y_i|}$$

Это MAE, делённая на средний |y|: какая доля общего объёма приходится на ошибку.

Плюсы

маленькие y не взрывают метрику: делим на сумму, а не на каждый объект

крупные объекты весят больше — обычно это и важно для бизнеса

Минусы

крупные объекты доминируют: ошибки на мелких почти не видны

по-прежнему нужно ∑|y| > 0

Шесть домов: WAPE = 0.54/64.2 ≈ 0.84%.

Максимальная ошибка и квантиль ошибки

Когда важен худший случай, а не средний

$$\mathrm{MaxError}(a, X) = \max_{i=1,\dots,l} |y_i - a(x_i)|$$

Квантиль ошибки: например, 95-й процентиль $|y - a(x)|$ — «95 % прогнозов ошибаются не больше чем на …».

Шесть домов

MaxError = 0.14 млн ₽ (дом 5)

Когда нужны

цена отдельного большого промаха очень высока: медицина, сроки доставки, гарантии клиенту (SLA)

средняя ошибка может быть маленькой, а один промах — катастрофическим

Осторожно

max error зависит от единственного объекта и очень шумная

квантиль ошибки (90 %, 95 %) устойчивее и обычно информативнее

Какой прогноз «любит» каждая метрика

Оптимальный константный прогноз — и к какому смещению это ведёт

Метрика / функция потерь	Оптимальная константа	Что это значит
MSE, RMSE	среднее	тянется за выбросами
MAE	медиана	устойчива к выбросам
Huber	между медианой и средним	регулируется порогом δ
квантильная ρ_τ	τ-квантиль	прогноз «с запасом» вверх или вниз
MSLE	$\exp(\text{среднее } \ln(y+1)) - 1$	ниже среднего: ближе к среднему геометрическому
MAPE	медиана с весами $1/y$	**систематически занижает прогноз**

Обучили на одной функции, а оцениваем другой метрикой — прогноз будет смещён. Хорошо, когда функция потерь согласована с метрикой. Например, MAPE — это MAE с весами $1/y$: если оцениваем по MAPE, можно обучать на взвешенной MAE.

Как выбрать метрику

Ситуация	Метрика
важны единицы ответа, большие промахи особенно вредны	RMSE
нужна «типичная» ошибка, в данных есть выбросы	MAE
нужно сравнить с константой, понять долю объяснённого разброса	R^2 (и R^2_{adj} при разном числе признаков)
важна относительная ошибка, y далеко от нуля	MAPE
относительная ошибка, но много маленьких y и нулей	WAPE
y меняется на порядки (от тысяч до миллионов)	MSLE / RMSLE
цена ошибки вверх и вниз разная	квантильная (pinball) loss
недопустимы отдельные большие промахи	max error, квантиль ошибки

Главная мысль: метрика приходит из задачи. Обычно смотрят на несколько метрик сразу — одну оптимизируют, остальные помогают не пропустить перекосы.

Метрики в sklearn

Модуль sklearn.metrics и строки scoring для cross_validate

Метрика	Функция	scoring
MSE	`mean_squared_error`	`neg_mean_squared_error`
RMSE	`root_mean_squared_error`	`neg_root_mean_squared_error`
MAE	`mean_absolute_error`	`neg_mean_absolute_error`
R^2	`r2_score`	`r2`
MSLE	`mean_squared_log_error`	`neg_mean_squared_log_error`
MAPE	`mean_absolute_percentage_error`	`neg_mean_absolute_percentage_error`
Max error	`max_error`	`max_error`

1 **neg_ в scoring**
в sklearn scoring всегда устроен как «больше — лучше», поэтому ошибки берут со знаком минус

2 **MAPE — доля, а не проценты**
mean_absolute_percentage_error вернёт 0.16, а не 16; WAPE и SMAPE пишутся в одну строку руками

Что мы обсудили

1. **ММП** — функция потерь равна −ln плотности шума: нормальный шум даёт MSE, шум Лапласа — MAE
2. **Требования для MSE** — линейность в среднем, независимые объекты, нормальный шум с одинаковой дисперсией
3. **Huber loss** — квадрат для маленьких ошибок и модуль для больших; δ задаёт границу между ними
4. **Метрика ≠ функция потерь** — метрика оценивает готовую модель на новых данных и должна приходить из задачи
5. **MSE, RMSE, MAE, R^2** — абсолютные ошибки и сравнение с константой; $R^2 < 0$ означает «хуже среднего»
6. **MAPE, SMAPE, WAPE, MSLE** — относительные ошибки со своими перекосами: оптимум метрики определяет смещение прогноза